

Актуальность

Нейронные сети широко применяются в системах, работающих в режиме реального времени: техническое зрение, робототехника, интеллектуальное видеонаблюдение, человеко-машинные интерфейсы. Для таких приложений важны не только точность предсказаний, но и гарантированные временные характеристики. При внедрении обученной модели в прикладную систему возникает задача её эффективного развертывания и оптимизации вывода под целевую аппаратную платформу. Классические фреймворки (например, PyTorch) удобны для разработки и обучения, однако в задачах развертывания требуется использование специализированных средств оптимизации вычислительного графа и исполнения на GPU. В экосистеме NVIDIA ключевую роль играет TensorRT, а также новый высокоуровневый фронтенд TriPy, ориентированный на производительный вывод и тесную интеграцию с TensorRT. Сравнение подходов и анализ компромисса “точность–быстродействие” позволяют сформировать практические рекомендации для задач реального времени.

Цель и задачи

Изучение технологий развертывания свёрточных нейронных сетей для приложений реального времени с использованием PyTorch и TriPy, а также сравнение точности и быстродействия моделей после экспорта в формат TensorRT.

1. Рассмотреть требования систем реального времени к выполнению вывода нейронных сетей;
2. Изучить архитектуру LeNet и адаптировать её для набора данных CIFAR-10;
3. Реализовать модель в PyTorch и TriPy и обеспечить эквивалентность вычислений;
4. Обучить модель на CIFAR-10;
5. Экспортировать реализацию в TensorRT (через PyTorch и через TriPy);
6. Сравнить точность и быстродействие.

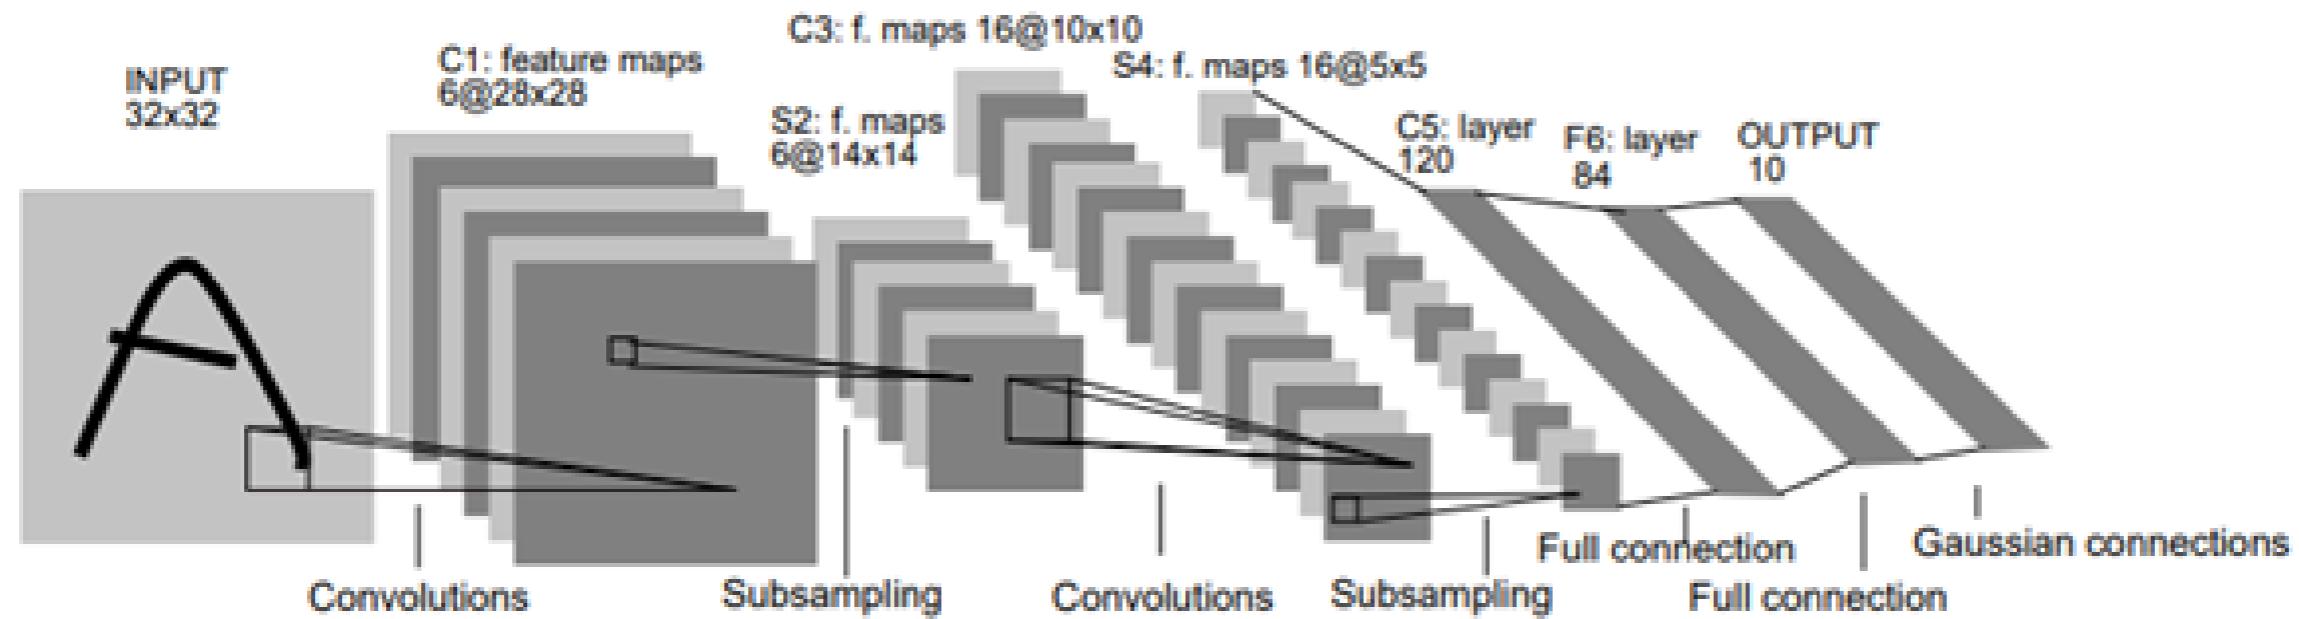
Изм.	Лист	№ докум.	Подп.	Дата	Лит.	Масса	Масштаб
Разраб.	Ефремов С.А.						
Пров.	Лычков И.И.						
Т.контр.							
Н.контр.							
Утв.							

Курсовая работа

Цель и задачи

Лист 1 Листов 5
МГТУ им. Н.Э. Баумана
группа ИУЗ-11М

Стандартная структура сети LeNet



Структура сети LeNet для CIFAR-10

Вход: 3×32×32 (RGB).

- Conv($3 \rightarrow 6$, $k=5 \times 5$) → ReLU → MaxPool(2×2 , $s=2$)
- Conv($6 \rightarrow 16$, $k=5 \times 5$) → ReLU → MaxPool(2×2 , $s=2$)
- Flatten($16 \times 5 \times 5 = 400$)
- FC($400 \rightarrow 120$) → ReLU
- FC($120 \rightarrow 84$) → ReLU
- FC($84 \rightarrow 10$) (логиты классов)

В качестве базовой модели выбрана свёрточная нейронная сеть LeNet, адаптированная под изображения CIFAR-10 (цветные RGB $3 \times 32 \times 32$, 10 классов). Архитектура является компактной (порядка 6.2×10^4 параметров), вычислительно умеренной и хорошо подходит для экспериментов по развертыванию и ускорению инференса, поскольку обеспечивает предсказуемую структуру вычислительного графа и небольшие требования к памяти.

Изм.	Лист	№ докум.	Подп.	Дата	Курсовая работа	
Разраб.	Ефремов С.А.				Архитектура	
Пров.	Лычков И.И.				LeNet	
Т.контр.						
Н.контр.						
Утв.						
						Лист 2 / Листов 5
						МГТУ им. Н.Э. Баумана группа ИУЗ-11М

Hyperbolic geometry

Подготовка данных

Для обучающей выборки применялась аугментация: случайное кадрирование 32×32 с padding=4 и случайное горизонтальное отражение. Далее выполнялись преобразование в тензор и нормализация по каналам RGB. Для тестовой выборки применялись только преобразование в тензор и нормализация.

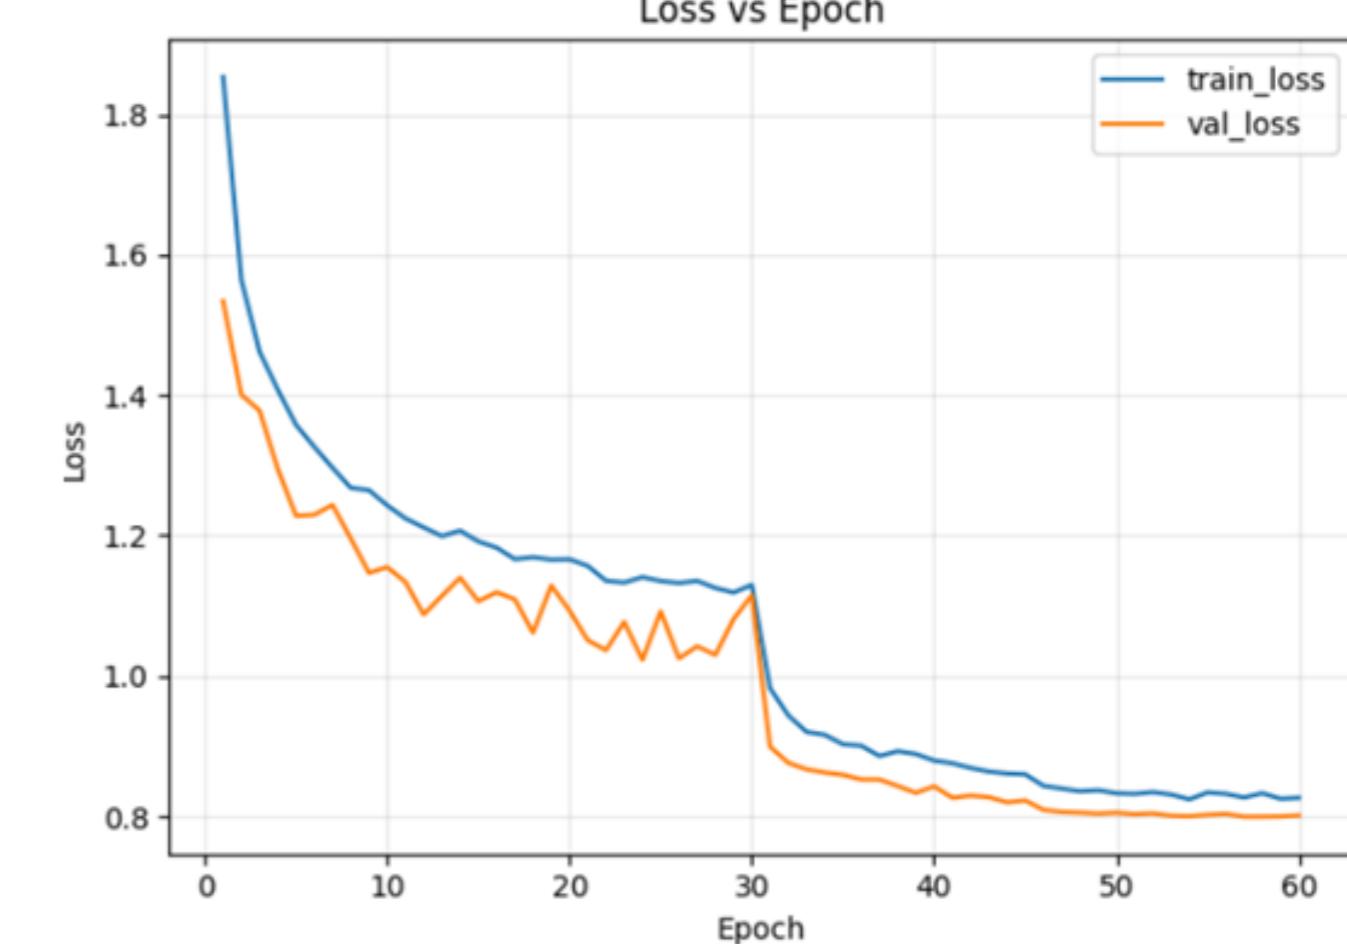


Рисунок 1 — График изменения средних потерь

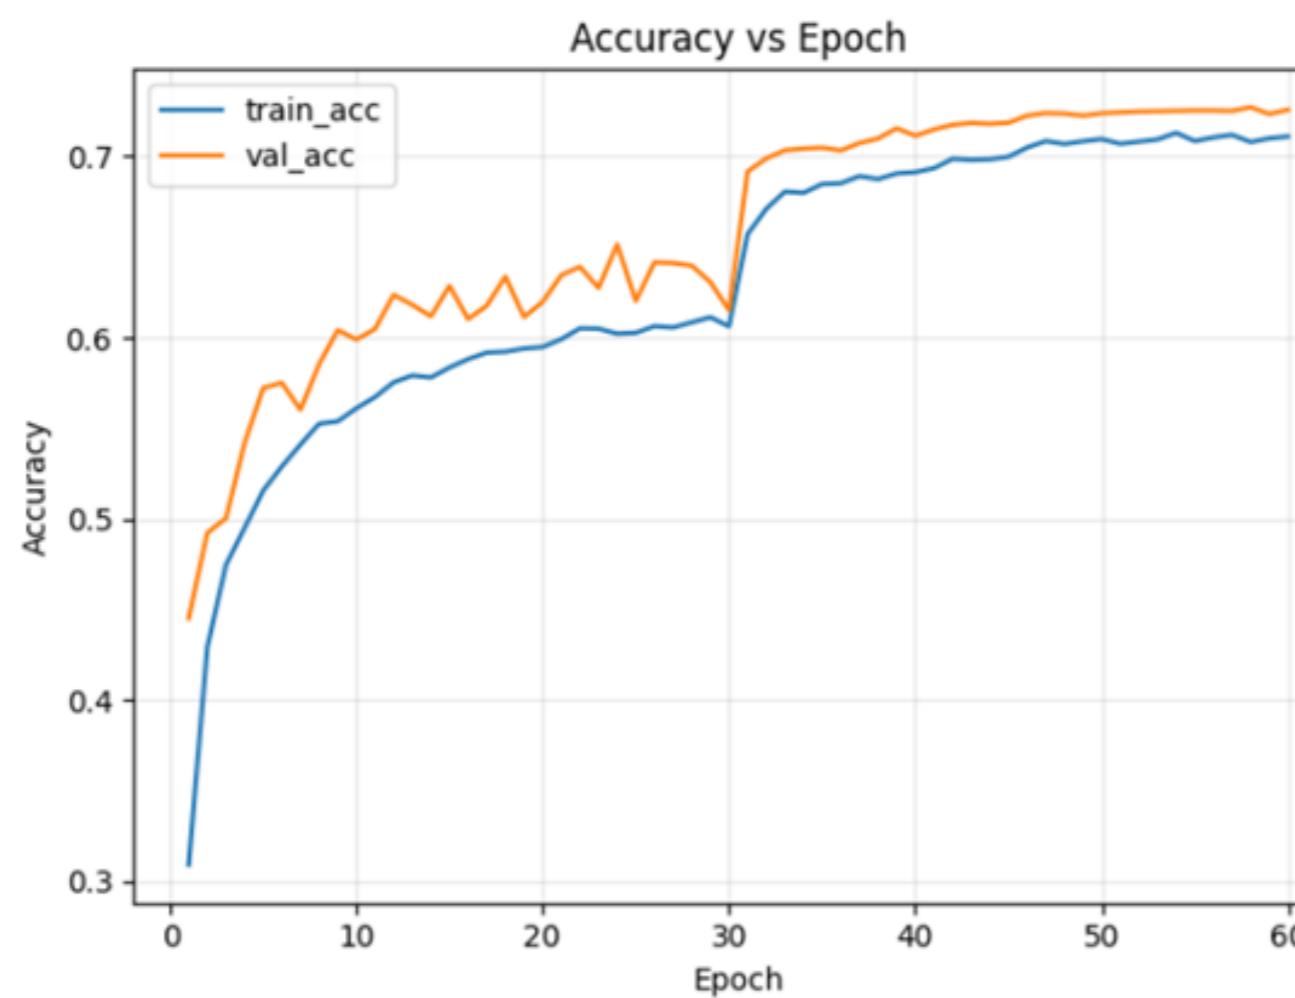


Рисунок 2 — График изменения точности

Размер батча: 200.
Оптимизатор: SGD (learning rate 0.05,
momentum 0.9, weight decay 5e-4).
План изменения learning rate: уменьшение в 10
раз после 30-й и 45-й эпох.
Число эпох: 60.

Реализация в TriPy

TriPy используется как высокоуровневый фронтенд, ориентированный на производительный вывод и тесно интегрированный с TensorRT. Архитектура TriPy-модели структурно повторяет PyTorch-вариант LeNet: два свёрточно-пулинговых блока и полносвязная часть классификатора.

Перенос параметров из PyTorch

```
def convert_state_torch_to_tripy(torch_state):
    tripy_state = {}
    for name, param in torch_state.items():
        np_value = param.detach().cpu().numpy().astype("float32")
        tripy_state[name] = tp.Tensor(np_value)
    return tripy_state
```

Для обеспечения сопоставимости результатов используются одни и те же обученные веса. Параметры PyTorch-модели конвертируются в формат TriPy (приведение к float32 и загрузка в tp.Tensor), затем загружаются в TriPy-модель. Такой перенос позволяет получить функционально эквивалентную реализацию для дальнейшего сравнения точности и скорости.

Сравнение результатов

PyTorch: loss = 0.7994318, accuracy = 0.7270;
TriPy: loss = 0.7994541, accuracy = 0.7269.

Незначительное расхождение носит ожидаемый характер и обусловлено особенностями численной реализации вычислений и преобразований данных при переходе между средами выполнения (округления, порядок операций с плавающей запятой). В целом результаты подтверждают, что TriPy-реализация воспроизводит качество PyTorch-модели с практически полным совпадением метрик.

Курсовая работа					
Реализация			Лист.	Масса	Масштаб
Изм.	Лист	№ докум.	Подп.	Дата	
Разраб.	Ефремов С.А.				
Пров.	Лычков И.И.				
Т.контр.					
Н.контр.					
Утв.					
Лист 4 Листов 5			МГТУ им. Н.Э. Баумана группа ИУЗ-11М		

Hyperbolic geometry

Результаты сравнения быстродействия

Среда выполнения	forward, мс/пакет	forward, мс/изобр.	e2e, мс/пакет	e2e, мс/изобр.
PyTorch	0,814	0,0008	1,702	0,0017
TensorRT	0,652	0,0007	1,620	0,0016
TriPy → TensorRT	0,548	0,0005	1,476	0,0015

Методика измерений производительности

Измеряются два режима

1. forward-only: входные данные находятся в GPU, учитывается только прямой проход модели;
 2. end-to-end: включает копирование CPU→GPU, вычисления и синхронизацию.

Анализ результатов

Оптимизация вычислительной части (forward-only):
TensorRT уменьшает время на $\approx 19.9\%$ относительно
PyTorch, а TriPy → TensorRT даёт уменьшение $\approx 32.7\%$
относительно PyTorch и $\approx 16.0\%$ относительно TensorRT

В режиме end-to-end эффект слабее из-за заметной доли времени на передачу данных и синхронизацию: TensorRT уменьшает e2e на $\approx 4.8\%$ относительно PyTorch, TriPy \rightarrow TensorRT на $\approx 13.3\%$ относительно PyTorch.

Условия эксперимента

Тестирование проводилось на CIFAR-10 (10 000 изображений) при одинаковой предобработке. Использовались warm-up 5 батчей и серия из 100 прогонов с усреднением. Оборудование: Ubuntu 24.04, CPU AMD Ryzen 5 7500F, RAM 32 ГБ DDR5, GPU NVIDIA GeForce RTX 4060 Ti 8 ГБ.